# 基於混合 LSTM-PPO 架構之極端市場環境動態資產配置研究

## 1. Introduction (研究簡介與動機)

在當前高度連動且數位化的金融體系中，市場結構性轉變（Regime Shift）已成為資產管理機構面臨的系統性挑戰。傳統的靜態配置模型與被動型投資策略，本質上依賴於歷史數據的平穩性假設。然而，當市場進入非平穩環境（Non-stationary Environment）時，資產間的線性相關性會迅速崩潰，導致傳統風險分散機制全面失效。在此背景下，開發具備環境感知與自我進化能力的深度強化學習（DRL）Agent，不僅是量化技術的升級，更是法人機構在極端市場中維持超額報酬（Alpha）的戰略必然。

### 1.1 研究背景與極端事件剖析

本專案以 **2026** 年 **3** 月 **4** 日台股重挫 **1,494** 點的極端尾部事件（Tail Event）作為壓力測試基準。該事件期間，VIX 指數長期待在高位，顯示市場進入了 Hambly et al. (2023) 所描述的「非平穩狀態」。在此情境下，金融數據的「常態分佈假設」完全失效，厚尾效應（Heavy-tail Effect）導致波動率出現非線性噴發。本研究旨在證明，唯有透過具備動態調整機制的 Agent，才能在這種分佈偏移（Distribution Shift）發生時，迅速從「探索（Exploration）」轉向「避險（Exploitation）」。

### 1.2 傳統策略之局限性 (The "But" Factor)

傳統被動型配置（如追蹤 0050）或移動平均（MA）策略在面對市場劇變時，存在致命的「指標落後性」：

- 決策維度失能：線性模型無法處理高維、具備隨機波動性（Stochastic Volatility）的金融數據。正如 Marcos Lopez de Prado 所言，線性迴歸在非線性動態系統中具有先天失能性，無法辨識潛藏於宏觀與微觀數據間的深度關聯。
- 馬可夫狀態欠缺：傳統技術指標僅是過去價格的滯後函數，無法滿足馬可夫決策過程（MDP）中「當前狀態需具備充分統計量」的要求。當 Regime Shift 發生時，指標的落後會導致策略在高波動初期反應遲鈍，進而造成毀滅性的最大回撤（Max Drawdown）。

### 1.3 研究方案優勢 (The "Cure")

為克服上述局限，本專案提出以「End-to-End DRL Agent」為核心的解決方案。本研究採用 **Hybrid LSTM + PPO** 雙核心架構，將長短期記憶網路（LSTM）在時間序列特徵萃取上的強項，與近端策略優化（PPO）的穩健決策特性完美結合。不同於傳統方法，此架構能透過與環境的持續回饋進行自我進化，主動感應環境狀態的變遷。

### 1.4 實驗設計與預期發現

本專案利用 2015-2024 年的大型歷史資料庫進行深度訓練，並在 2025-2026 年區間進行樣本外（OOS）測試。針對 2026 年 3 月的極端波動區間，我們將執行滾動式驗證（Walk-Forward Validation）。

- 量化目標：預計將 Max Drawdown 壓縮至 **15%** 以內。
- 預期效益：透過風險調整後報酬的最佳化，實現全面超越基準指標（Benchmark）的 Sharpe Ratio，確立 Agent 在極端環境下的生存優勢。

## 2. Related Work (相關文獻探討)

文獻樹狀圖

### 2.1 時序預測模型 (Time Series Prediction Models)

早期的量化研究主要聚焦於價格的點預測。Jue Xiao 等人 (2024) 比較了 LSTM、GRU 與 Transformer 在股票預測上的表現。研究指出，LSTM 在處理單一價格序列時展現出極高的穩健性（Robustness）；然而，此類純預測模型的共同缺點在於「特徵單一性」，且 Transformer 在多資產情境下的結論未必可直接套用，缺乏對交易決策的直接引導能力。

### 2.2 深度強化學習 (DRL) 交易

為了解決預測與交易脫鉤的問題，學界開始導入 DRL。2024 年至 2025 年間的多篇應用科學（Applied Sciences）期刊文獻，證實了 PPO、DDPG 與 SAC 等演算法在多國市場表現穩定，且優於傳統的移動平均（MA）交叉策略。部分前沿研究（如 2024 年期刊文獻）更進一步將交易成本與滑價（Slippage）納入考量。然而，這些研究的痛點在於模型過於複雜、訓練成本高昂，且在「極端市場（High Volatility Market）」下的策略表現極不穩定。

## 2.3 DRL 投資組合優化 (Portfolio Optimization)

在資產配置層面，Nawathe 等人 (2024) 提出了多模態深度強化學習（Multimodal DRL），並探討了不同的獎勵函數（如利潤獎勵與下行風險 DSR 獎勵）。此類研究的優點在於實驗設計清晰，並開始關注風險調整指標。但其致命缺點在於：(1) DSR 獎勵在牛市中表現較差，導致過度保守；(2) 超參數調整過多，複製困難；(3) 在高波動市場中，所有演算法皆表現不穩，亟需額外的風險管理機制。

## 2.4 基準策略比較 (Benchmark Comparison)

多項實證分析指出，DRL 策略在累積報酬與風險調整指標上，普遍優於 Buy-and-Hold 與傳統靜態配置。但這些文獻的共同結論也再次強調了 DRL 面臨的困境：計算資源需求極高，且面對 Regime Shift（市場狀態轉變）時，缺乏防禦深淵回撤的能力。

## 2.5 本研究之切入點與創新 (Research Gap & Our Contribution)

總結上述四大領域的文獻，當前 DRL 交易系統的「整體缺點」集中於兩大痛點：一是高波動市場中策略不穩定（亟需外部風險管理）；二是多模態與多特徵資料的處理門檻過高，導致實務落地困難。

針對這些研究缺口，本專案提出之 **Risk-Aware PPO-LSTM** 架構 具備以下突破：

1. 解決高波動不穩定性：捨棄傳統單一獎勵，將最大回撤懲罰（MDD Penalty）直接內建於 Reward 函數中（$R_t = Sharpe_t - \alpha \times Drawdown$），以此取代外部風險管理，強制 Agent 在極端市場中主動降權防禦。
2. 解決特徵處理門檻：透過系統化的 Feature Pipeline 與 LSTM Encoder，將複雜的總經指標（VIX、殖利率）與 OHLCV 價格矩陣進行降維與時序特徵萃取，有效降低多變數模型的訓練難度與超參數複雜性，達成兼顧學術嚴謹性與實務落地性的動態資產配置系統。

# 3. Proposed Design (系統設計與方法論)

本專案將動態資產配置建模為馬可夫決策過程(MDP)，以應對非平穩環境下的極端市場決策。為了解決純技術分析的指標落後性，本專案設計了一套端到端(End-to-End)的「Risk-Aware PPO-LSTM」系統架構，並規劃了結合大型語言模型(LLM)的進階擴充路徑。

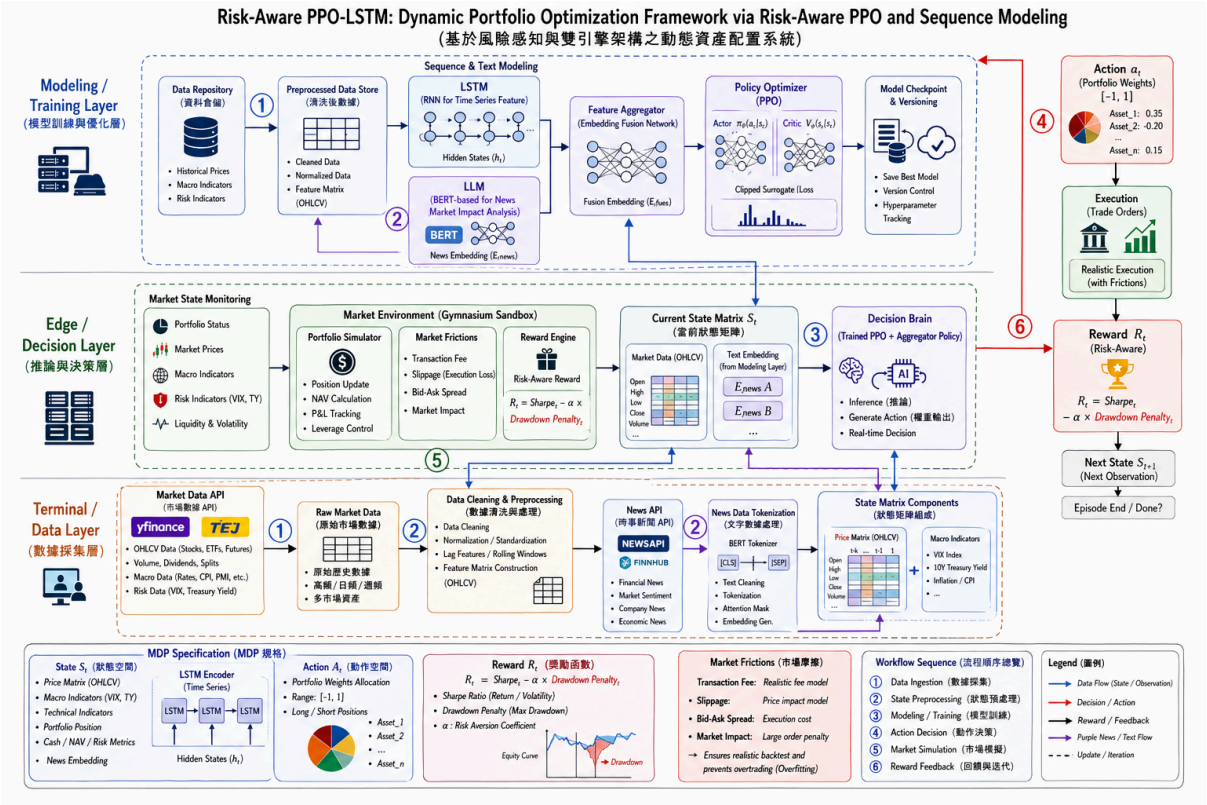


系統架構圖

## 3.1 三層式系統架構與資料流 (Three-Tier Architecture & Data Flow)

本系統在邏輯上解耦了「沉重運算」與「即時推論」，分為以下三大層級：

1. **Terminal / Data Layer (數據採集層)**：負責從 yfinance 與 TEJ API 採集多維度量價數據與總經指標(如 VIX、美債殖利率)，並進行正規化與特徵工程。此外，規劃透過 News API 抓取財經新聞作為進階資料源。
2. **Edge / Decision Layer (推論與決策層)**：部署訓練完成的大腦(Decision Brain)。接收當前狀態矩陣 $S_t$ 後，Agent 會在極低延遲下產出連續型的資金配置權重(Action $a_t$)，並於客製化的 Gymnasium 沙盒環境中執行交易，結算真實損益。
3. **Modeling / Training Layer (模型訓練與優化層)**：運用本地算力執行深度學習與梯度更新。包含負責萃取特徵的 LSTM 網路、負責策略優化的 PPO 演算法，以及儲存經驗軌跡的資料庫(Data Repository)。

## 3.2 核心引擎與多模態擴充 (Core Engines & Multimodal Extension)

本專案在傳統的深度強化學習框架上，規劃了雙腦協同與特徵融合機制：

- 時序感知大腦 **(The Forecaster - LSTM)**：擔任微觀預警者。LSTM 層專注於處理 OHLCV 與總經特徵中的時間相依性（Temporal Dependence），其輸出的「隱藏狀態向量（Hidden States）」能有效捕捉市場動能與潛在的 Regime Shift。
- 穩健決策大腦 **(The Risk Controller - PPO)**：擔任總指揮。基於 Actor-Critic 架構，利用 PPO 的「剪裁目標函數（Clipped Surrogate Loss）」確保策略更新的平滑性，防止 Agent 在極端波動下產生過激的權重調整。
- 文本情緒解析大腦 **(The Context Analyzer - LLM) [進階擴充 / Optional]**：考量到純價格數據屬於落後指標，本專案期望導入基於 BERT 架構的語言模型作為右腦。透過解析即時新聞並生成文本嵌入向量（News Embedding），再經由特徵融合網路（Feature Aggregator）與 LSTM 向量結合，賦予 Agent 宏觀的時事視野。（註：此多模態整合為本專案之進階挑戰目標，後續將視專案開發時程與運算資源彈性評估是否完整實作。）

## 3.3 馬可夫決策過程 (MDP) 規格定義

- **State (S_t)**：狀態空間整合了價格矩陣、總經領先指標，以及規劃擴充的新聞文本向量（Text Embedding）。這構成了一個高維度的綜合狀態表徵，確保 Agent 具備充分的決策統計量。
- **Action (a_t)**：採用連續型權重分配，區間設定為 $[-1, 1]$。這打破了傳統僅限多頭配置的限制，賦予 Agent 靈活運用放空與避險部位的權力。
- **Reward (R_t)**：

$$R_t = \text{Sharpe}_t - \alpha \times \text{Drawdown Penalty}_t$$

- 深度解讀：此為本專案最具創新性的「風險感知獎勵（Risk-Aware Reward）」。公式中的 $\alpha$ 作為風險偏好調節閥，直接在優化目標中引入對最大回撤（Max Drawdown）的嚴格懲罰。此機制強制 Agent 必須在追求資本增長與控制下行風險之間取得平衡，從根本上解決了傳統 PPO 容易過度曝險的缺陷。

## 3.4 實驗環境與市場摩擦 (Market Frictions)

為確保實驗結果具備實務落地價值，本專案堅決捨棄理想化的靜態回測框架。

- 高度擬真沙盒：系統內部採用 Gymnasium 框架建置市場環境，並強制寫入真實的滑價 **(Slippage)** 與交易手續費 **(Transaction Fee)**。
- 防禦過度擬合：引入交易摩擦能迫使 Agent 具備「換手成本意識」，自動過濾掉微小且頻繁的雜訊交易。此設計保證了策略在樣本外（OOS）極端壓力區間測試時，能展現出穩健的生存能力。